

# Tree-based Methods

Petchara Pattarakijwanich

Introduction to Data Science, 4 November 2022

# Goal of this week

- Binary Tree
  - Regression Tree
  - Classification Tree
- Purity Metrics
  - Classification Error Rate
  - Gini Index
  - Entropy
- Methods to Improve Binary Tree
  - Bagging
  - Random Forest
  - Boosting

# About the Final Project

## Approaches


- Answer specific questions from data, using data science techniques
- Implement, invent, or test some data science techniques or algorithms

## Data Source

- Your own research
- Publicly available datasets  
<https://geekflare.com/open-datasets-for-data-science/>  
<https://www.dataquest.io/blog/free-datasets-for-projects/>
- Simulated data (?)

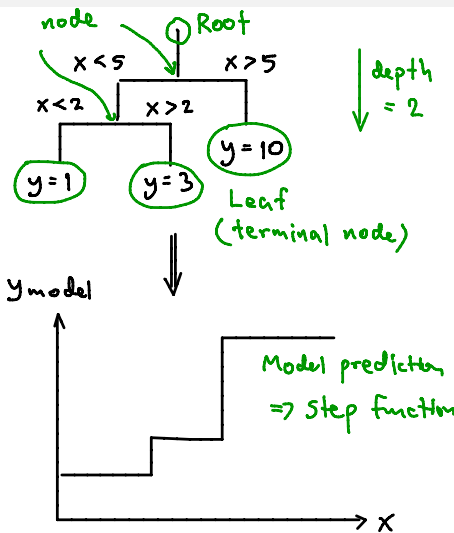
## Presentation (some time around final week or a bit later)

# Regression Tree





หาค่าที่ดีที่สุด?  
 $\Rightarrow$  หาค่าที่ "ดี" ที่น้อย  
 (minimize MSE)

## Binary Tree




# Regression Tree

บทที่ 2 ใหม่





$y_i =$  ค่าที่คำนวณได้จากฟังก์ชัน  
การถดถอย



Model Prediction

Step function Approximation

# Classification Tree



ค่าที่นำค่ามาของ node  
= mode ของ node นั้น

ตัดที่จุดไหน & อย่างไร? ตัดอย่างไรดี "ดี"

Purity metric

- Error Rate
  - Gini Index
  - Entropy
- ← ง่ายต่อการใช้
- } ให้นับ

# How to Grow Trees

Input  $\{x_1, x_2, \dots, x_n\}$  output  $\{y\}$

① เลือก Root

② หารู้อย่างไรที่จะหาจุดแบ่งซ้าย & ขวาให้ดีที่สุด

- ลองหาค่า  $x_1 \rightarrow$  หารู้อย่างไรที่จะหาค่าที่ดีที่สุด
- ลองหาค่า  $x_2 \rightarrow$  หารู้อย่างไรที่จะหาค่าที่ดีที่สุด
- $\vdots$
- เปรียบเทียบหาค่า  $x_i$  ที่ค่า  $x_i = ?$

ทำซ้ำ  
จนพอใจ

- หารู้อย่างไร  $\rightarrow$  regression
- หารู้อย่างไร  $\rightarrow$  classification

อัตรา


- Regression  $\Rightarrow$  MSE หารู้อย่างไร
- Classification

$\Rightarrow$  Purity หารู้อย่างไร

③ หยุดเมื่อไหร่?

- ไม่หยุดหาค่า  $\Rightarrow$  หารู้อย่างไร node หารู้อย่างไร  $\Rightarrow$  over fit
- หยุดเมื่อหารู้อย่างไร "ดี" หารู้อย่างไร
- หยุดที่ depth หารู้อย่างไร

# Purity Metrics



node ใน tree

รวม 10

เขียว 5


น้ำเงิน 5

วัดความ "pure" ของ node นี้ได้อย่างไร?

- Error Rate
- Gini Index
- Shannon Entropy



# Classification Error Rate



$$E = 1 - P_{k, \max}$$

ทำนายที่ถูกต้องคือ mode  
 $\Rightarrow$  mode ของ

แดง 10

เขียว 5

น้ำเงิน 5

$\Rightarrow$

$$P_{\text{แดง}} = \frac{1}{2}$$

$$P_{\text{เขียว}} = \frac{1}{4}$$

$$P_{\text{น้ำเงิน}} = \frac{1}{4}$$

ทำนายที่ถูกต้อง = 10

$$\Rightarrow \text{accuracy} = \frac{10}{20}$$

$$\text{accuracy} = \frac{10}{20} = 0.5$$


$\uparrow$   
Error Rate

$$P_k = \begin{cases} P_{\text{แดง}} \\ P_{\text{เขียว}} \\ P_{\text{น้ำเงิน}} \end{cases}$$

$$P_{k, \max} = P_{\text{แดง}} = 0.5$$

$$E = 1 - P_{k, \max} = 0.5$$

# Gini Index



$$P_{\text{red}} = \frac{1}{2}$$

$$P_{\text{green}} = \frac{1}{4}$$

$$P_{\text{blue}} = \frac{1}{4}$$

$$G = \sum_k P_k(1-P_k) = 1 - \sum_k P_k^2$$

နံပါတ် ၁ ခုစာ + နံပါတ် ၁ နဲ့  
⇒ လက်ခံသတ်ဝေမှု အသုံးပြုမှု

$$G = P_{\text{red}}(1-P_{\text{red}})$$

$$+ P_{\text{green}}(1-P_{\text{green}})$$

$$+ P_{\text{blue}}(1-P_{\text{blue}})$$

↑  
prob မှုက-က  
နံပါတ်

↑  
prob မှုက-က  
label အမှန်အကဲ

# Gini Index


$$G = P_{\text{has}}(1 - P_{\text{has}}) + P_{\text{no}}(1 - P_{\text{no}}) + P_{\text{other}}(1 - P_{\text{other}})$$

$$= P_{\text{has}} - P_{\text{has}}^2 + P_{\text{no}} - P_{\text{no}}^2 + P_{\text{other}} - P_{\text{other}}^2$$

$$= 1 - P_{\text{has}}^2 - P_{\text{no}}^2 - P_{\text{other}}^2$$

$$G = 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{4}\right)^2 - \left(\frac{1}{4}\right)^2 = \dots$$

# Shannon Entropy



$$P_{\text{red}} = \frac{1}{4}$$

$$P_{\text{green}} = \frac{1}{4}$$

$$P_{\text{blue}} = \frac{1}{4}$$

$$D = - \sum_k P_k \log_2 P_k$$

"Information" of Event with prob  $p$

$$I = \log_2 \left( \frac{1}{p} \right) = -\log_2 p$$

↑ "Information"  $p$  low  $\rightarrow$   $I$  is


$$I_A + I_B = \log_2 \left( \frac{1}{P_A} \right) + \log_2 \left( \frac{1}{P_B} \right)$$

$$= \log_2 \left( \frac{1}{P_A P_B} \right)$$

$$= \log_2 \left( \frac{1}{P(A \cup B)} \right)$$

↑  
Information  
of 2 event

# Shannon Entropy



$$P_{\text{red}} = \frac{1}{4}$$

$$P_{\text{green}} = \frac{1}{4}$$

$$P_{\text{blue}} = \frac{1}{4}$$

Entropy = Expected value of Information

$$= \langle I \rangle$$

$$= \sum_k P_k I_k$$

$$= \sum_k P_k \log_2 \left( \frac{1}{P_k} \right)$$


$$= - \sum_k P_k \log_2 P_k$$

$$D = - P_{\text{red}} \log_2 P_{\text{red}} - P_{\text{green}} \log_2 P_{\text{green}} - P_{\text{blue}} \log_2 P_{\text{blue}} = \dots$$


# Purity Metrics

พิจารณา 2 class  $\begin{cases} + , \text{ prob } p \\ - , \text{ prob } 1-p \end{cases}$


$$E = 1 - p_{k, \max} = \begin{cases} 1-p, & p \geq 0.5 \\ p, & p < 0.5 \end{cases}$$




$$G = 1 - \sum_k p_k^2 = 1 - p^2 - (1-p)^2$$



$$D = - \sum_k p_k \log_2 p_k = -p \log_2 p - (1-p) \log_2 (1-p)$$




# Purity Metrics



# Information Gain

$$\Delta I = I_P - \underbrace{\frac{N_L}{N_P} I_L - \frac{N_R}{N_P} I_R}_{\text{ค่าเฉลี่ยถ่วงน้ำหนักของ } I_L, I_R}$$

ค่าเฉลี่ยถ่วงน้ำหนักของ  $I_L, I_R$




$\Delta I > 0 \Rightarrow$  แบ่งแล้ว纯度เพิ่มขึ้น  
 $\Rightarrow$  Purity เพิ่มขึ้น

$\Delta I$  ยิ่งมากยิ่งดี

แบ่งแล้ว纯度เพิ่มขึ้น? ค่าไหนดี?  $\Rightarrow$  ให้น  $\Delta I$  มาก



# Information Gain



Parent  $N_P = 9$  ,  $P_{\text{class}} = \frac{7}{9}$  ,  $P_{\text{class}} = \frac{2}{9}$

$$G_P = 1 - \sum_k P_k^2 = 1 - P_{\text{class}}^2 - P_{\text{class}}^2 = 1 - \left(\frac{7}{9}\right)^2 - \left(\frac{2}{9}\right)^2 = 0.35$$

Left child  $N_L = 4$  ,  $P_{\text{class}} = 1$  ,  $P_{\text{class}} = 0$

$$G_L = 1 - P_{\text{class}}^2 - P_{\text{class}}^2 = 0$$

Right child  $N_R = 5$  ,  $P_{\text{class}} = \frac{3}{5}$  ,  $P_{\text{class}} = \frac{2}{5}$



$$G_R = 1 - P_{\text{class}}^2 - P_{\text{class}}^2 = 1 - \left(\frac{3}{5}\right)^2 - \left(\frac{2}{5}\right)^2 = 0.48$$

# Information Gain

$$\Delta G = G_p - \frac{N_L}{N_p} G_L - \frac{N_R}{N_p} G_R$$

$$= 0.35 - \frac{4}{9} \times 0 - \frac{5}{9} \times 0.48$$

$$= 0.08 > 0 \quad \Rightarrow \text{แบ่ง ดีกว่าไม่แบ่ง}$$



ปรับปรุง



- เพิ่ม node purity
- แบ่ง node ย่อย  
ต่อไป

# Pros and Cons of Classification Tree

ข้อดี

- ใช้งานได้ Qualitative variable ง่าย
- ใช้งานได้ทั้ง continuous variable

(การตัดสินใจแบบ step-by-step  
มันง่ายกว่าการหาสมการ?)



ข้อเสีย

- Variance สูง
  - Prediction Accuracy ต่ำ
- } over fit ง่าย

- แก้ด้วย Bagging  
Random Forest  
Boosting