

Support Vector Machine


Petchara Pattarakijwanich

Introduction to Data Science, 18 November 2022

Goal of this week

- Support Vector Machine
 - Linearly Separable Data
 - Hyperplanes
 - Maximal Margin Classifier
 - Soft Margin Classifier
 - Kernels
 - Support Vector Machine
- Neural Network?

Linearly Separable Data & Separating Hyperplane




มี Hyperplane แยกได้ 100%
 \Rightarrow Linearly Separable Data

แนวทางการหา "Hyperplane"
 \uparrow
สมการเส้นตรง

Linearly Separable Data & Separating Hyperplane

1 มิติ




\Rightarrow hyperplane 0 มิติ (จุด)

$$x = x_0 = a_0 n$$

$$\Rightarrow \beta_0 + \beta_1 x = 0$$

2 มิติ




hyperplane 1 มิติ (เส้นตรง)

$$x_2 = m x_1 + c$$

$$\Rightarrow \beta_0 + \beta_1 x_1 + \beta_2 x_2 = 0$$

3 มิติ




hyperplane 2 มิติ (ระนาบ)

$$\Rightarrow \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 = 0$$

n มิติ \Rightarrow hyperplane n-1 มิติ

สมการ hyperplane $\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n = 0 \Rightarrow \beta_0 + \vec{\beta} \cdot \vec{x} = 0$

Linearly Separable Data & Separating Hyperplane




separating hyperplane is unique

⇒ อย့်หาเส้น?

⇒ อย့်หาจุด Margin อย့်สุด

↑
ขนาดของ Margin อย့်ใหญ่

Linearly Separable Data & Separating Hyperplane




● = support vector

(Maximal Margin Hyperplane
ใช้ support vector ในการ
หาเส้นแบ่ง)

Maximal Margin Classifier

Math Background for Hyperplane




จุด \vec{a}, \vec{b} อยู่บนระนาบ $\Rightarrow \vec{b} - \vec{a}$ อยู่บนระนาบ

$$\Rightarrow \vec{\beta} \perp \vec{b} - \vec{a} \Rightarrow \vec{\beta} \cdot (\vec{b} - \vec{a}) = 0 \Rightarrow \vec{\beta} \cdot \vec{b} = \vec{\beta} \cdot \vec{a}$$

$\Rightarrow \vec{\beta} \cdot \vec{x} = \text{ค่าคงที่}$ (นิยามจุด \vec{x} ใดๆ ที่อยู่บนระนาบ)

$$\beta_0 + \vec{\beta} \cdot \vec{x} = 0 \quad \text{สมการระนาบ}$$

Math Background for Hyperplane



$$\vec{p} \cdot (\vec{x} - \vec{a}) = \underbrace{|\vec{p}| |\vec{x} - \vec{a}| \cos \theta}_{=d}$$

if $|\vec{p}| = 1$, \vec{p} = unit vector

$$\Rightarrow d = \vec{p} \cdot (\vec{x} - \vec{a})$$

\vec{p} : normal vector
 \vec{x} : vector from origin to point
 \vec{a} : vector from origin to point on hyperplane

$$d = \beta_0 + \vec{p} \cdot \vec{x}$$

$d > 0$: data point is above hyperplane

$d < 0$: data point is below hyperplane


$d = 0$: on hyperplane

$$\beta_0 + \vec{p} \cdot \vec{x} = 0 \quad \text{for all } \vec{x} \text{ on hyperplane}$$

$$\beta_0 + \vec{p} \cdot \vec{a} = 0$$

$$\Rightarrow \vec{p} \cdot \vec{a} = -\beta_0$$

Math Background for Hyperplane




$$d = \beta_0 + \vec{\beta} \cdot \vec{x}$$

[រូបមន្តនេះ ផ្តល់នូវចម្ងាយ
ពីចំណុច \vec{x} ទៅនឹងប្លង់អ៊ីព័រផ្ទៃបំបែក
រូបមន្តនេះ = $|d|$]

$$d = y(\beta_0 + \vec{\beta} \cdot \vec{x})$$

[រូបមន្តនេះ ផ្តល់នូវចម្ងាយ]

Maximal Margin Classifier



where $\beta_0, \vec{\beta} = \beta_1 \hat{e}_1 + \beta_2 \hat{e}_2 + \dots + \beta_n \hat{e}_n$
 find the M margin for the data
 constraints with $\beta_0, \beta_1, \beta_2, \dots, \beta_n$

① $\beta_1^2 + \beta_2^2 + \dots + \beta_n^2 = 1$

[$\vec{\beta}$ is unit vector]

② $y_i (\beta_0 + \vec{\beta} \cdot \vec{x}_i) \geq M$
 for all i


[the distance from hyperplane
 to the data points is M]

Convex Quadratic Optimization
 (if the data is linearly separable, the algorithm will find it)

Maximal Margin Classifier

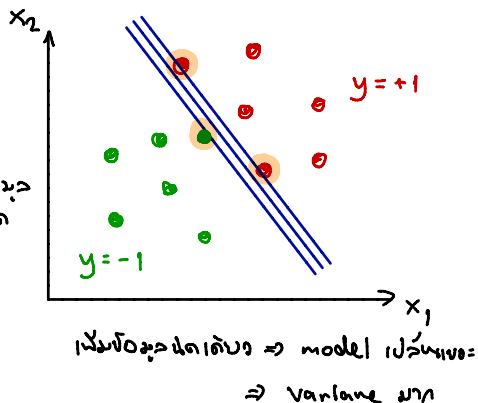
ข้อดี : ง่าย ใช้งานได้จริง

ข้อเสีย : - มีเงื่อนไขให้ \mathbf{x} (ไม่ linearly separable)
- Variance ใหญ่



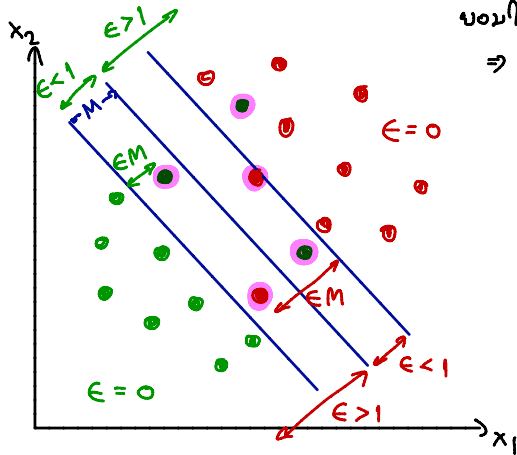
\Rightarrow Hard Margin

\Rightarrow
เพิ่มจำนวน
จุด



เพิ่มจำนวนจุดให้เยอะ \Rightarrow model เปลี่ยนบ่อย
 \Rightarrow Variance มาก

Soft Margin Classifier



ขอบข่ายของ margin


\Rightarrow หาผลรวมของ slack variable ϵ

ϵ = ระยะของ margin
 $\epsilon \geq 0$ (ค่าบวก)

C = ขอบรวมค่า slack variable
 รวมกันทั้งหมด

$$\sum_i \epsilon_i \leq C$$

Soft Margin Classifier



Convex Quadratic Optimization

for C values $\rightarrow C=0 \Rightarrow$ MMC

$\rightarrow C$ margin ကို

C ကို Margin ကို

where $\beta_0, \beta_1, \beta_2, \dots, \beta_n$ and n is the number of features

$$\textcircled{1} \quad \beta_1^2 + \beta_2^2 + \dots + \beta_n^2 = 1$$

[$\vec{\beta}$ = unit vector]

$$\textcircled{2} \quad y_i(\beta_0 + \vec{\beta} \cdot \vec{x}_i) \geq M(1 - \epsilon_i)$$

for all i

[where $\epsilon_i = 0$, if $\epsilon_i > 0$]

$$\textcircled{3} \quad \epsilon_i \geq 0 \text{ for all } i$$


$$\textcircled{4} \quad \sum \epsilon_i \leq C$$

[where C is a constant]

if C is large \Rightarrow Linearly separable
if C is small \Rightarrow $C \geq C_{crit}$

Soft Margin Classifier


C သိသိကျွန် [test data, cross validation]



C သိသိကျွန် \Rightarrow M သိသိကျွန်
 \Rightarrow အများဆုံး SV သိသိကျွန်

\Rightarrow Variance နည်း
 \Rightarrow Bias မြင့်

Bias-Variance
Trade off





C သိသိကျွန် \Rightarrow M သိသိကျွန်
 \Rightarrow အနည်းဆုံး SV သိသိကျွန်

\Rightarrow Variance မြင့်
 \Rightarrow Bias နည်း

Kernels


ทำให้อันที่ 0 และ 1 แยกกัน?



\Rightarrow ใช้ Kernel

Kernels

1D data




Not separable \Rightarrow separable

Soft Margin (Linear) Classifier

หา $\beta_0, \vec{\beta}$ ที่ทำให้ M มากที่สุด
โดยที่ \dots

2D data

$$x_2 = (x_1 - a)^2$$



Soft Margin Classifier + Kernel


หา $\beta_0, \vec{\beta}, \alpha$ ที่ทำให้ M มากที่สุด
โดยที่ \dots

Kernel

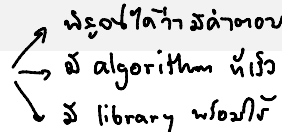
Kernels

Kernel functions

- polynomial (vsu order)
- Radial Basis function (vsu γ)



Kernels

- Convex Quadratic Optimization 
 - ไม่มี algorithm ทั่วไป
 - มี algorithm ทั่วไป
 - มี library ทั่วไป

- Kernel Optimize

- ความสะดวก dot product $\vec{x}_i \cdot \vec{x}_j$ \Rightarrow
$$\begin{pmatrix} \vec{x}_1 \cdot \vec{x}_1 & \vec{x}_1 \cdot \vec{x}_2 & \dots \\ \vec{x}_2 \cdot \vec{x}_1 & \vec{x}_2 \cdot \vec{x}_2 & \dots \\ \vdots & \dots & \ddots \end{pmatrix}$$
 แทนด้วย vector \vec{x}_i

- Kernel \equiv ความสะดวก dot product ทั่วไป


- Linear $K(\vec{x}_i, \vec{x}_j) = \vec{x}_i \cdot \vec{x}_j$

- Polynomial $K(\vec{x}_i, \vec{x}_j) = P_n(\vec{x}_i \cdot \vec{x}_j)$

- RBF $K(\vec{x}_i, \vec{x}_j) \propto e^{-\gamma P_n(\vec{x}_i \cdot \vec{x}_j)}$


dot product คือ
"ความคล้าย" ของ \vec{x}_i, \vec{x}_j
 > 0 , คล้ายกัน
 $= 0$, ไม่คล้าย
 < 0 , ขัดแย้งกัน

Kernels



ວິທີ 4

- ໂພລິໄນອົມຊຶມວິທີ "ເຈັບ" ນອກ ສອດຄ່າ \bar{x}
- ຖ້າຖອດຂໍ້ເຈັບ ມາແບບ 2 ຄ່າ



SVM

- ໂພລິໄນອົມ
- (ຈຸດແກ້ວທີ່ຖືກໂຈ້ງ, ຈຸດເປັນທີ່ຖືກໂຈ້ງ)
- ຖານວ = support vector
- ຖ້າ sv ມາຮັບ classifier

Kernel = ນັກວິທະຍາທີ່ນຳໃຊ້ non-linear